

EMR

APARTADO A

Realiza el laboratorio:

Laboratorio de AWS Builder

Analyze Big Data with Hadoop (Español de España)

★ 4.0 (3)

Básico

1h

Español (España)

En él se analizan datos de Amazon CloudFront, servicio de AWS que genera registros de acceso que muestran todos los datos solicitados por los usuarios, con el siguiente formato (se explica el contenido de cada campo en el laboratorio):

```
*****
**** SAMPLE LOG DATA ****
*****

2017-07-05 20:05:47 SEA4 4261 10.0.0.15 eabcd12345678.cloudfront.net /test-image-
2.jpeg Mozilla/5.0%20(MacOS;%20U;%20Windows%20NT%205.1;%20en-
US;%20rv:1.9.0.9)%20Gecko/2009040821%20Chrome/3.0.9
```

Analyze Big Data with Hadoop (Español de España)

Laboratorio de AWS Builder | ★ 4.0 (3) | 1h | Español (España) +10 más |

Detalles

Esquema

Para empezar con esta formación, debes matricularte

Matricularse

Análisis de Big Data con Hadoop (Español de España)

Comenzar 

EJERCICIO 1

Task 1: Create an Amazon S3 bucket

In this task, you create an S3 bucket to store your log files and output data.

- 3. At the top of the AWS Management Console, in the search bar, search for and choose  **S3**.
- 4. Choose **Create bucket**.


On the **Create bucket** page, configure the following:

- For **Bucket name**, enter  **hadoopNUMBER**.

 **Note:** Replace **NUMBER** with a random number.

- Choose **Create bucket**.

 **Task complete:** You have successfully created an S3 bucket to store your log files and output data.



The screenshot shows the AWS Management Console search results for 'S3'. The search bar at the top contains 's3' and a 'Preguntar a Amazon Q' button. Below the search bar, the 'Servicios' section is highlighted, showing 'S3' as the selected service with the description 'Almacenamiento escalable en la nube'. Below this, the 'Buckets de uso general' page is shown, displaying a table of existing buckets. The table has columns for 'Nombre', 'Región de AWS', and 'Fecha de creación'. Two buckets are listed: 'awslabs-resources-krxqqla59sui8d-us-east-1-893599163230' and 'awslabs-resources-r5b3y6ojjszcap-us-east-1-893599163230', both in the 'EE.UU. Este (Norte de Virginia) us-east-1' region.

Nombre	Región de AWS	Fecha de creación
awslabs-resources-krxqqla59sui8d-us-east-1-893599163230	EE.UU. Este (Norte de Virginia) us-east-1	3 Oct 2020 12:10:25 AM CEST
awslabs-resources-r5b3y6ojjszcap-us-east-1-893599163230	EE.UU. Este (Norte de Virginia) us-east-1	20 Oct 2023 9:02:20 PM CEST

Crear bucket [Información](#)

Los buckets son contenedores de datos almacenados en S3.

Configuración general

Región de AWS
EE.UU. Oeste (Oregón) us-west-2

Tipo de bucket [Información](#)

☒ **Uso general**
Recomendado para la mayoría de los casos de uso y patrones de acceso. Los buckets de uso general son del tipo de bucket de S3 original. Permiten una combinación de clases de almacenamiento que almacenan objetos de forma redundante en múltiples zonas de disponibilidad.

☐ **Directorio**
Recomendado para casos de uso de baja latencia. Estos buckets utilizan únicamente la clase de almacenamiento S3 Express One Zone, que proporciona un procesamiento más rápido de los datos dentro de una única zona de disponibilidad.

Nombre del bucket [Información](#)

hadoop11678

Los nombres de los buckets deben tener entre 3 y 63 caracteres y ser únicos dentro del espacio de nombres global. Los nombres de los buckets también deben empezar y terminar con una letra o un número. Los caracteres válidos son a-z, 0-9, puntos (.) y guiones (-). [Más información](#)

Copiar la configuración del bucket existente: opcional
Solo se copia la configuración del bucket en los siguientes ajustes.

Elegir el bucket

Formato: s3://bucket/prefijo

► Configuración avanzada

Después de crear el bucket, puede cargar archivos y carpetas, y configurar ajustes adicionales en él.

Cancelar Crear bucket

El bucket "hadoop11678" se creó correctamente
Para cargar archivos y carpetas, o para configurar ajustes adicionales del bucket, elija Ver detalles.

Buckets de uso general

Todas las regiones de AWS

Buckets de directorio

Buckets de uso general (3)

Información

Los buckets son contenedores de datos almacenados en S3.

Buscar buckets por nombre

< 1 > ⚙

	Nombre	Región de AWS	Fecha de creación
☐	awslabs-resources-krxqqla59sui8d-us-east-1-893599163230	EE.UU. Este (Norte de Virginia) us-east-1	3 Oct 2020 12:10:25 AM CEST
☐	awslabs-resources-r5b3y6ojjszcap-us-east-1-893599163230	EE.UU. Este (Norte de Virginia) us-east-1	20 Oct 2023 9:02:20 PM CEST
☐	hadoop11678	EE.UU. Oeste (Oregón) us-west-2	8 Jan 2026 9:39:47 AM CET

Copiar ARN

Vaciar

Eliminar

Crear bucket

Instantánea de la cuenta

Información

Ver panel

Actualizado a diario

Storage Lens ofrece visibilidad sobre el uso del almacenamiento y las tendencias de actividad.

Resumen de acceso externo: nuevo

Información

Actualizado a diario

Los resultados de acceso externo le ayudan a identificar los permisos de los buckets que permiten el acceso público o desde otras cuentas de AWS.

Task 2: Launch an Amazon EMR cluster

In this task, you launch a Hadoop cluster, and then use it to process data.

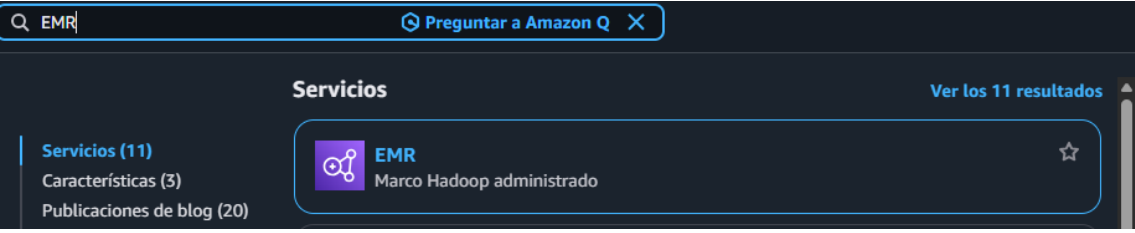
5. At the top of the AWS Management Console, in the search bar, search for and choose **EMR**.
6. Ensure the region located at the top of your screen matches the value of **Region** located to the left of these instructions. If your region does not match, change your region to the value of **Region**.
7. Choose **Create cluster**.
8. On the **Create cluster** page, in the **Name and applications - required** section, configure the following:
 - For **Name**, enter **My cluster**.
 - For **Amazon EMR release**, select **emr-5.36.1** from the dropdown menu.
 - For **Application bundle**, choose **Custom** and select the following applications if not already selected:
 - ☒ Hue
 - ☒ Hadoop
 - ☒ Hive
 - ☒ Pig
9. In the **Cluster configuration - required** section, configure the following:
 - Choose **Uniform instance groups**.
 - For **Primary, Core and Task 1 of 1**, select **m4.large** from the **Choose EC2 instance type** dropdown menu.

EJERCICIO 2

Task 2: Launch an Amazon EMR cluster

In this task, you launch a Hadoop cluster, and then use it to process data.

5. At the top of the AWS Management Console, in the search bar, search for and choose  **EMR**.
6. Ensure the region located at the top of your screen matches the value of **Region** located to the left of these instructions. If your region does not match, change your region to the value of **Region**.
7. Choose .
8. On the **Create cluster** page, in the **Name and applications - required** section, configure the following:
 - For **Name**, enter .
 - For **Amazon EMR release**, select **emr-5.36.1** from the dropdown menu.
 - For **Application bundle**, choose **Custom** and select the following applications if not already selected:
 - ☒ Hue
 - ☒ Hadoop
 - ☒ Hive
 - ☒ Pig
9. In the **Cluster configuration - required** section, configure the following:
 - Choose **Uniform instance groups**.
 - For **Primary**, **Core** and **Task 1 of 1**, select **m4.large** from the **Choose EC2 instance type** dropdown menu.
10. In the **Networking - required** section, configure the following:
 - For **Virtual private cloud (VPC)** choose .
 - On the **Choose VPC** pop-up window, select the radio button next to **Lab VPC**.
 - Choose .
 - Expand the **EC2 security groups (firewall)** section, and for **EMR-managed security group** select the security group containing the name **xxxx-EmrSecurityGroup-xxxx** for both **Primary node** and **Core and task nodes**.
11. In the **Cluster termination and node replacement** section, de-select ☐ **Use termination protection**.
12. Expand the **Cluster logs** section, and configure the following:
 - Select ☒ **Publish cluster-specific logs to Amazon S3**.
 - For **Amazon S3 location**, choose .
 - On the **Choose Amazon S3 location** pop-up window, select the radio button next to the Hadoop bucket name that was created earlier, and choose .
13. In the **Security configuration and EC2 key pair** section, configure the following:
 - For **Amazon EC2 key pair for SSH to the cluster**, choose .
 - On the **Choose Amazon EC2 key pair for SSH to cluster** pop-up window, select the radio button next to the key pair named **EMRKey-lab** and choose .
14. In the **Identity and Access Management (IAM) roles - required** section, configure the following:
 - For **Amazon EMR service role**, select **EMR_DefaultRole** from the **Service role** dropdown menu.
 - For **EC2 instance profile for Amazon EMR**, select **EMR_EC2_DefaultRole** from the **Instance profile** dropdown menu.
15. Choose .
-  **Note:** The cluster takes approximately five minutes to launch. Please continue reading while waiting for the cluster to launch.



clústeres (0) [Información](#)

Filtrar clústeres por estado

Buscar clústeres

Filtrar clústeres por fecha y hora de creación

< 1 >

	ID del clúster	Nombre del clúster	Estado	Hora de creación (UTC+01:00)	Tiempo transcurrido	Horas de instancia normalizadas
No hay clústeres						
No hay clústeres que mostrar.						

Nombre

My cluster


Versión de Amazon EMR [Información](#)

Una versión contiene un conjunto de aplicaciones que se puede instalar en el clúster.

emr-5.36.1

⚠ El soporte para esta versión de EMR finalizará May-01-2026, por lo que ya no podrá recibir soporte técnico. AWS recomienda encarecidamente que ponga en marcha sus cargas de trabajo en la versión más reciente de Amazon EMR para recibir actualizaciones y correcciones críticas para la seguridad. También puede usar el nuevo agente de actualización de Spark para actualizar las aplicaciones existentes en la versión 5.40 o superior a la última versión de EMR. Para obtener más información, consulte [Política de soporte estándar de EMR](#) y [Actualizaciones de Spark](#)

Paquete de aplicaciones

Spark 	Core Hadoop 	HBase 	Presto 	Custom 
--	--	--	---	---

- | | | |
|--|---|--|
| ☐ Flink 1.14.2 | ☐ Ganglia 3.7.2 | ☐ HBase 1.4.13 |
| ☐ HCatalog 2.3.9 | ☒ Hadoop 2.10.1 | ☒ Hive 2.3.9 |
| ☒ Hue 4.10.0 | ☐ JupyterEnterpriseGateway 2.6.0 | ☐ JupyterHub 1.4.1 |
| ☐ Livy 0.7.1 | ☐ MXNet 1.8.0 | ☐ Mahout 0.13.0 |
| ☐ Oozie 5.2.1 | ☐ Phoenix 4.14.3 | ☒ Pig 0.17.0 |
| ☐ Presto 0.267 | ☐ Spark 2.4.8 | ☐ Sqoop 1.4.7 |
| ☐ TensorFlow 2.4.1 | ☐ Tez 0.9.2 | ☐ Zeppelin 0.10.0 |
| ☐ ZooKeeper 3.4.14 | | |

▼ Configuración del clúster - **obligatorio** [Información](#)

Elija un método de configuración para los grupos principales, centrales y de nodos tareas para su clúster.



Grupos de instancias uniformes

Elija el mismo tipo de instancia de EC2 y la misma opción de compra (bajo demanda o de spot) para todos los nodos de su grupo de nodos. [Más información](#) 



Flotas de instancias flexibles

Elija entre la más amplia variedad de opciones de aprovisionamiento para las instancias de EC2 de su clúster. Diversifique los tipos de instancias y las opciones de compra, y utilice una estrategia de asignación. [Más información](#) 

Grupos de instancias uniformes

Principal

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria

Únicamente EBS almacenamiento

Precio bajo demanda: -

Precio de spot más bajo: -

Acciones ▼



Utilice la alta disponibilidad

Lance un clúster más resiliente y de alta disponibilidad con tres nodos principales en instancias bajo demanda. Esta configuración se aplica durante toda la vida útil del clúster. [Más información](#) 

► Configuración de nodo - *opcional*

Central

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria

Únicamente EBS almacenamiento

Precio bajo demanda: -

Precio de spot más bajo: -

Acciones ▼

► Configuración de nodo - *opcional*

► Configuración de nodo - *opcional*

Tarea 1 de 1

Eliminar grupo de instancias

Nombre

Tarea - 1

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria

Únicamente EBS almacenamiento

Precio bajo demanda: -

Precio de spot más bajo: -

Acciones ▼

► Configuración de nodo - *opcional*

Elegir VPC

VPC (2)

Filtrar VPC

< 1 >

Nombre	ID de VPC	Condición	CIDR IPv4	CIDR IPv6
☒ Lab VPC	vpc-0775c7a839e39c0c3	✓ Disponible	10.1.0.0/16	
☐ -	vpc-02fa7b44f6c1e740d	✓ Disponible	172.31.0.0/16	

Cancelar

Elegir

▼ Redes - obligatorio

Información

Elija la configuración de red que determina la forma en que usted y otras entidades se comunican con su clúster.

Virtual Private Cloud (VPC)

Información

vpc-0775c7a839e39c0c3

Examinar

Crear VPC

Subred

Información

subnet-014f22b82d10d40dc

Examinar

Crear subred

▼ Grupos de seguridad de EC2 (firewall)

Nodo principal

Grupos de seguridad administrados de EMR

EMR actualizará automáticamente el grupo seleccionado.

LabStack-c7c5ec7e-ba65-4d76-b678-61abbb...
sg-03ffabe0c82cb2fe5

Grupos de seguridad adicionales - opcional

Seleccione hasta 4 grupos de seguridad adicionales.

Elegir grupos de seguridad adicionales

Nodos principales y de tareas

Grupos de seguridad administrados de EMR

EMR actualizará automáticamente el grupo seleccionado.

LabStack-c7c5ec7e-ba65-4d76-b678-61abbb...
sg-03ffabe0c82cb2fe5

Grupos de seguridad adicionales - opcional

Seleccione hasta 4 grupos de seguridad adicionales.

Elegir grupos de seguridad adicionales

▼ Terminación del clúster y reemplazo de nodos [Información](#)

Elija la configuración de terminación y proteja su clúster contra un apagado accidental.

Opción de terminación

- ☐ Terminar manualmente el clúster
- ☐ Terminar automáticamente el clúster después de que finalice el último paso
- ☒ Terminar el clúster después del tiempo de inactividad (recomendado)

Tiempo de inactividad

Ingrese el tiempo hasta que el clúster termine.

0 días ▼

01:00:00

Elija una hora mayor a 1 minuto (00:01:00) y menor a 7 días. La hora está en formato hh:mm:ss (24 horas).

☐ Use la protección contra la terminación

Protege al clúster para evitar una terminación accidental. Si está activada, deberá primero desactivar la protección para terminar el clúster. Recomendamos activar la protección frente a terminaciones para los clústeres de larga duración.

Reemplazo de nodos en mal estado - [novedad](#) | [Información](#)

☐ Activar

Amazon EMR detiene correctamente los procesos en los nodos en mal estado para minimizar la pérdida de datos y las interrupciones del trabajo. Reemplaza rápidamente los nodos en mal estado por nuevas instancias de EC2 para que sus trabajos funcionen sin problemas.

☒ Desactivar

Amazon EMR agrega los nodos en mal estado a una lista de denegación mientras los mantiene en el clúster, lo que le permite tener acceso continuo para solucionar problemas.

Elegir la ubicación de Amazon S3

Buckets de S3

Buckets (1/3)

Q Buscar bucket

Nombre

- ☐ awslabs-resources-krxqqla59sui8d-us-east-1-893599163230
- ☐ awslabs-resources-r5b3y6ojjszcap-us-east-1-893599163230
- ☒ hadoop11678

Cancelar

Elegir

▼ Registros de clúster [Información](#)

Elija dónde y cómo almacenar los archivos de registro.

i Archivamos automáticamente los archivos de registro en Amazon S3. Puede especificar una ubicación de S3 propia o utilizar la ubicación de S3 predeterminada para Amazon EMR. La ubicación de registro predeterminada se completa previamente en el campo **Ubicación de Amazon S3**.

- ☒ Publicar registros específicos del clúster en Amazon S3

Ubicación de Amazon S3

Q s3://hadoop11678

X

Ver ↗

Explorar S3

Formato: utilizar s3://bucket/prefix

- ☐ Cifrar los registros específicos del clúster

Elegir una clave de Amazon EC2 para el protocolo SSH al cl ster

Pares de claves (1)

Buscar pares de claves

ID	Name	Fingerprint
☒ key-0d055892a608dcb1c	EMRKey-lab	cc:ff:a0:7a:04:04:70:78:7f:2a:01:87:83:94:81:29:e8:98:a5:ff

Cancelar

Elegir

▼ Configuraci n de seguridad y par de claves de EC2

Informaci n

Elija una configuraci n de seguridad o cree una nueva que pueda reutilizar con otros cl steres.

Configuraci n de seguridad

Seleccione la configuraci n del servicio de cifrado, autenticaci n, autorizaci n y metadatos de instancia del cl ster.

Elegir una configuraci n de seguridad

Examinar

Crear configuraci n de seguridad

Par de claves de Amazon EC2 para el protocolo SSH al cl ster

Informaci n

EMRKey-lab

Examinar

Crear par de claves

▼ Roles de Identity and Access Management (IAM) - obligatorio

Informaci n

Elija o cree un rol de servicio y un perfil de instancia para las instancias de EC2 del cl ster.

Rol de servicio de Amazon EMR

Informaci n

El rol de servicio es un rol de IAM que Amazon EMR asume para aprovisionar recursos y realizar acciones de nivel de servicio con otros servicios de AWS.

☒ Elegir un rol de servicio existente

Seleccione un rol de servicio predeterminado o un rol personalizado con pol ticas de IAM asociadas para que el cl ster pueda interactuar con otros servicios de AWS.

☐ Crear un rol de servicio

Deje que Amazon EMR cree un nuevo rol de servicio para que pueda conceder y restringir el acceso a los recursos de otros servicios de AWS.

Rol de servicio

EMR_DefaultRole

Perfil de instancia de EC2 para Amazon EMR

El perfil de instancia asigna un rol a cada instancia de EC2 de un cl ster. El perfil de instancia debe especificar un rol que pueda acceder a los recursos de los pasos y las acciones de arranque.

☒ Elegir un perfil de instancia existente

Seleccione un rol predeterminado o un perfil de instancia personalizado con pol ticas de IAM asociadas para que el cl ster pueda interactuar con sus recursos de Amazon S3.

☐ Crear un perfil de instancia

Deje que Amazon EMR cree un nuevo perfil de instancia para que pueda especificar un conjunto personalizado de recursos a los que tendr  acceso en Amazon S3.

Perfil de instancia

EMR_EC2_DefaultRole

Resumen Información

Nombre y aplicaciones - *obligatorio*

Nombre

My cluster

Versión de Amazon EMR

emr-5.36.1

Paquete de aplicaciones

Custom (Hadoop 2.10.1, Hive 2.3.9, Hue 4.10.0, Pig 0.17.0)

Configuración del clúster - *obligatorio*

Grupos de instancias uniformes

Principal (m4.large), Central (m4.large), Tarea (m4.large)

Aprovisionamiento y escalado de clústeres - *obligatorio*

Configuración de aprovisionamiento

Tamaño del núcleo: 1 instancia

Tamaño de la tarea: 1 instancia

Cancelar

Crear clúster

✓ El clúster "My cluster" se ha creado correctamente.

My cluster

⚠ El soporte para esta versión de EMR finalizará May-01-2026, por lo que ya no podrá recibir soporte técnico. AWS recomienda actualizaciones y correcciones críticas para la seguridad. También puede usar el nuevo agente de actualización de Spark para obtener más información, consulte [Política de soporte estándar de EMR](#) y [Actualizaciones de Spark](#).

▼ Resumen

Información del clúster

ID del clúster

j-2AMNXZPCE3CH8

ARN del clúster

 arn:aws:elasticmapreduce:us-west-2:893599163230:cluster/j-2AMNXZPCE3CH8

Configuración del clúster

Grupos de instancias

Capacidad

1 Primary (Principal) | 1 Principal | 1 Tarea

Aplicaciones

Versión de Amazon EMR

emr-5.36.1

Aplicaciones instaladas

Hadoop 2.10.1, Hive 2.3.9, Hue 4.10.0, Pig 0.17.0

Propiedades

Acciones de arranque

Instancias (hardware)

Pasos

Aplicaciones

C

EJERCICIO 3


Task 3: Process Your Sample Data by Running a Hive Script

In this task, you run a Hive script in your cluster as a *step* in the Amazon EMR console to process your sample data. In Amazon EMR, a *step* is a unit of work that contains one or more Hadoop jobs. You can submit *steps* when you create the cluster or when the cluster is running (if it is a long-running cluster).

ⓘ **Caution:** Wait until your cluster is showing a status of **Waiting**.

🔄 **Refresh:** If your cluster is not yet in the *Waiting* state, wait for 10 minutes and choose the refresh  icon. Try again every few minutes until the cluster status is *Waiting*.

16. Choose the **Steps** tab.

17. Choose .

On the **Add step** page, configure the following:

- For **Type**, choose **Hive program**.
- For **Name**, enter  `Process logs`.
- For **Hive script location**, enter  `s3://<REGION>.elasticmapreduce.samples/cloudfront/code/Hive_CloudFront.q` in the search textbox.

📌 **Note:** Replace **<REGION>** with the value of **Region** located to the left of these instructions.

- For **Input Amazon S3 location - optional**, enter  `s3://<REGION>.elasticmapreduce.samples` in the search textbox.

📌 **Note:** Replace **<REGION>** with the value of **Region** located to the left of these instructions.

- For **Output Amazon S3 location - optional**:
 - Choose .
 - On the **Choose Amazon S3 location** pop-up window, select the radio button next to the Hadoop bucket name that was created earlier, and choose .
- For **Arguments - optional**, enter  `-hiveconf hive.support.sql11.reserved.keywords=false`

18. Choose **Add step**.

The status of the step changes from *Pending* to *Running* to *Completed* as the step runs.

The step takes approximately one minute to run.

 **Knowledge check:** What the script is doing?

 **Answer:** The Hive script does the following:

- Creates a Hive table named *cloudfront_logs*.
- Reads the CloudFront log files from Amazon S3 and parses the files using the Regular Expression Serializer/Deserializer (*RegEx SerDe*).
- Writes the parsed results to the *cloudfront_logs* Hive table.
- Submits a HiveQL query against the data to retrieve the total requests per operating system for a given time frame.
- Writes the query results to your Amazon S3 output bucket.

The sample data set contains approximately 5000 rows of data. This same process, however, can be used to process *millions of rows of data* in parallel across multiple nodes.

19. Wait for the status of the step to change to **Completed**.

 **Refresh:** To update the status, choose the refresh  icon.

Your results are now available for viewing.

 **Task complete:** You successfully ran a Hive script in your cluster as a *step* in the Amazon EMR console to process your sample data.

Propiedades | Acciones de arranque | Instancias (hardware) | **Pasos** | Aplicaciones | Configuraciones | Monitorización | Eventos | Etiquetas (0)

Pasos (0) Información

Cada paso es una unidad de trabajo que contiene instrucciones para manipular los datos para su procesamiento por software instalado en el clúster.

Pasos simultáneos: 1

Filtrar pasos por estado

Q Buscar pasos

Actualizar tabla

Cancelar pasos

Clonar paso

Agregar paso

ID de paso

Estado

Nombre

Archivos de registro

Hora de creación (UTC+01:00)

Hora de inicio (UTC+01:00)

Tiempo transcurrido

No hay coincidencias

No se encuentra ninguna coincidencia

Configuración de pasos

Tipo

☐ JAR personalizado
Agrega un paso que le permite escribir un script personalizado para procesar los datos utilizando el lenguaje de programación Java.

☒ Programa de Hive
Agrega un paso que envía un script de Hive para las interacciones de almacenamiento de datos.

☐ Script de shell
Solucione los problemas que se presentan con el clúster.

☐ Programa de transmisión
Agrega un paso que utiliza la entrada estándar para ejecutar scripts de asignación/reducción y enviar los resultados a la salida estándar.

☐ Programa de Pig
Agrega un paso que envía un script de Pig para analizar conjuntos de datos de gran tamaño.

Nombre

Process logs

Ubicación del script de Hive

La ubicación Amazon S3 del script de Hive.

s3://us-west-2.elasticmapreduce.samples/cloudfront/code/Hive_CloudFront.q

×

Ver ^L

Explorar S3

Entrada de la ubicación de Amazon S3 - *opcional*

La ubicación Amazon S3 de los archivos de entrada de Hive.

s3://us-west-2.elasticmapreduce.samples

×

Ver ^L

Explorar S3

Salida de la ubicación de Amazon S3 - *opcional*

La ubicación Amazon S3 de los archivos de salida de Hive.

s3://hadoop11678

×

Ver ^L

Explorar S3

Argumentos - *opcional* | Información

Especifique los argumentos opcionales para su script.

-hiveconf hive.support.sql11.reserved.keywords=false

Acción de paso

Acción si se produce un error en el paso

La acción a tomar cuando se produce un error en el paso.

☒ Continuar
Pasa al siguiente paso de la cola.

☐ Cancelar y esperar
Cancela los pasos pendientes y devuelve el clúster al estado de espera.

☐ Terminar clúster
Cierra el clúster.

Cancelar

Agregar paso

Pasos (1) [Información](#)

Cada paso es una unidad de trabajo que contiene instrucciones para manipular los datos para su procesamiento por software instalado en el clúster.

Pasos simultáneos: 1 [i](#)

Filtrar pasos por estado

Q Buscar pasos

	ID de paso	Estado	Nombre	Archivos de registro ^L	Hora de creación (UTC+01:00)	Hora de inicio (UTC+01:00)	Tiempo transcurrido
☐	s-013839958V8HKW7S4JX	Completed	Process logs	No se han creado registros aún ^C	8 de enero de 2026, 10:08	8 de enero de 2026, 10:08	1 minuto, 32 segundos

EJERCICIO 4

Task 4: View the Results

After the step completes successfully, the query output produced by the Hive script is stored in the Amazon S3 bucket that you specified when you submitted the step.

In this task, you view the results of the query output produced by the Hive script.

20. At the top of the AWS Management Console, in the search bar, search for and choose  **S3**.
21. Choose the link to your *Hadoop* bucket.
22. Choose the **os_requests** folder.

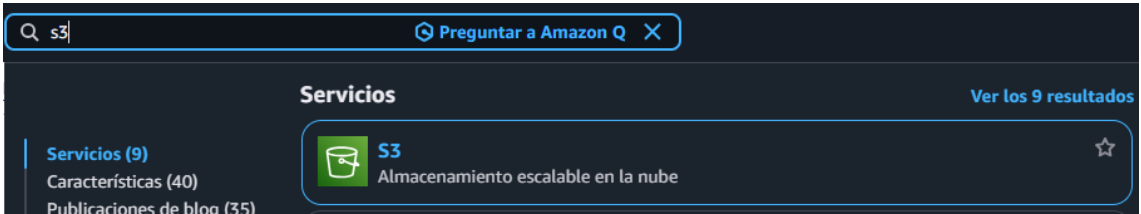
The Hive query results are stored in text files.

23. Download each file.
24. Open the files using a text editor such as WordPad (Windows), TextEdit (Mac OS), or gEdit (Linux).

In the output files, you should see the number of access requests by operating system:

This lab used a small sample of data. Normally, there would be significantly more rows of data in your CloudFront logs. Regardless of the size, the cluster automatically distributes the work across the cluster to complete the work required.


 **Task complete:** You have successfully viewed the results of the query output produced by the Hive script.



Buckets de uso general (3) Información			
Los buckets son contenedores de datos almacenados en S3.			
Buscar buckets por nombre			
	Nombre	Región de AWS	Fecha de creación
☐	awslabs-resources-krxqqla59sui8d-us-east-1-893599163230	EE.UU. Este (Norte de Virginia) us-east-1	3 Oct 2020 12:10:25 AM CEST
☐	awslabs-resources-r5b3y6ojjszcap-us-east-1-893599163230	EE.UU. Este (Norte de Virginia) us-east-1	20 Oct 2023 9:02:20 PM CEST
☐	hadoop11678	EE.UU. Oeste (Oregón) us-west-2	8 Jan 2026 9:39:47 AM CET

Objetos (3) Copiar URI de S3 Copiar URL Descargar Abrir Eliminar Acciones Crear carpeta Cargar							
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 para obtener una lista de todos los objetos de su bucket. Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. Más información							
Buscar objetos por prefijo							
☐	Nombre	Tipo	Última modificación	Tamaño	Clase de almacenamiento		
☐	i-2AMNXZPCE3CH8/	Carpeta	-	-	-		
☐	os_requests_\$folder\$	-	8 Jan 2026 10:09:35 AM CET	0 B	Estándar		
☐	os_requests/	Carpeta	-	-	-		

Objetos (1/2) Copiar URI de S3 Copiar URL Descargar Abrir Eliminar Acciones Crear carpeta Cargar							
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 para obtener una lista de todos los objetos de su bucket. Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. Más información							
Buscar objetos por prefijo							
☐	Nombre	Tipo	Última modificación	Tamaño	Clase de almacenamiento		
☒	000000_0	-	8 Jan 2026 10:10:21 AM CET	36.0 B	Estándar		
☐	000001_0	-	8 Jan 2026 10:10:21 AM CET	24.0 B	Estándar		



EJERCICIO 5

Task 5 : Connect to the EMR cluster CLI and perform query using HiveQL

In this task, you connect to the EMR cluster using SSH tool. Once you access the EMR cluster, you switch to Hive application and run query using HiveQL.


25. **Copy edit:** Copy the **CommandHostSessionManagementUrl** from the left of this instruction and paste it on a new tab of your browser.

You are redirected to the command host terminal.

26. **Command:** In the terminal, copy and paste below commands:

27. Type ☐ **yes** for the prompt.

Command: Type ☐ **hive** in the terminal and press **enter**.



EJERCICIO 6


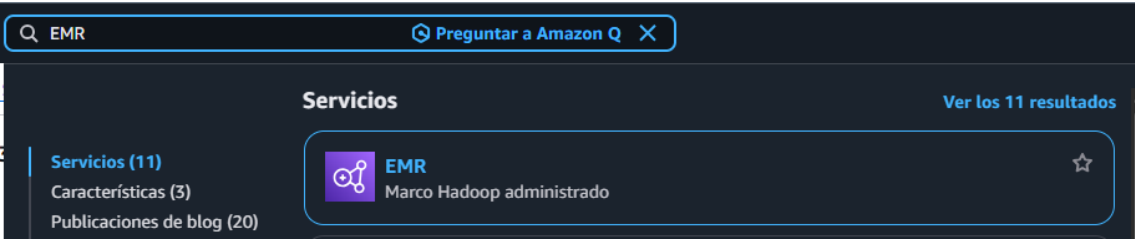
Task 6: Terminate your Amazon EMR Cluster

The cluster can be used to process many more jobs and can also be used interactively instead of submitting pre-built jobs.

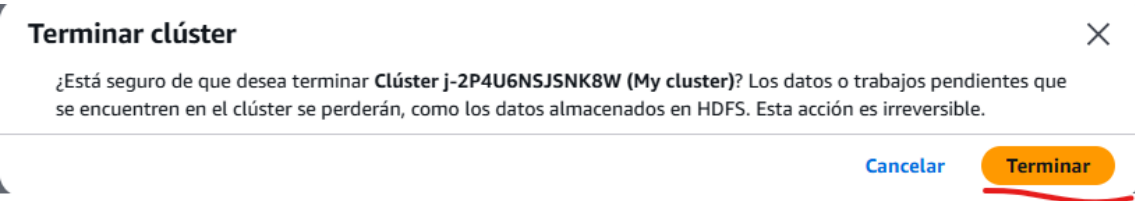
In this task, you *terminate* the cluster, since it is no longer required for this lab.

- 1. Return to the **AWS Management Console** browser tab.
- 2. At the top of the AWS Management Console, in the search bar, search for and choose  **EMR**.
- 3. In the left navigation pane, Choose **Clusters**.
- 4. Select ☒ **My cluster**.
- 5. Choose .
- 6. On the **Terminate cluster** pop-up window, choose .

 **Task complete:** You have successfully terminated the EMR cluster.



Clústeres (1/1) Información							
Filtrar clústeres por estado		Buscar clústeres		Filtrar clústeres por fecha y hora de creación			
☒	ID del clúster	Nombre del clúster	Estado	Hora de creación (UTC+01:00)	Tiempo transcurrido	Horas de instancia normalizadas	
☒	j-2AMNXZPCE3CH8	My cluster	Esperando Listo después de completar el paso	8 de enero de 2026 9:54	27 minutos, 51 segundos	0	



Confirm complete lab



Completing the lab will also end the lab session. Make sure all tasks have been completed and you are done using the lab environment.

[Cancelar](#)[Complete Lab](#)

Analyze Big Data with Hadoop (Español de España)

laboratorio de AWS Builder | ★ 4.0 (3) | 1h | Español (España) +10 más



¡Enhorabuena!

Esta formación la finalizaste el January 8, 2026

[Explorar el catálogo](#)[Volver al inicio](#)

APARTADO B

Realiza el laboratorio:

Laboratorio de AWS Builder

Exploring Google Ngrams with Amazon EMR and Hive (Español de España)

★ 4.5 (2) | Avanzado | 1h 15m | Español (España)

Realiza este laboratorio creando el clúster EMR desde AWS ACADEMY (en estos caso no uses el entorno que te propone el curso)

Una vez creado el clúster EMR en AWS ACADEMY, conéctate a él vía ssh como ya hicimos en otras prácticas y comienza el laboratorio desde el apartado:

11. Escribe `hive` en el terminal y pulsa `enter`. Se te redirigirá a la aplicación de Hive.

▼ Nombre y aplicaciones - obligatorio [Información](#)

Asigne un nombre a su clúster y elija las aplicaciones que desea instalar en él.

Nombre

Versión de Amazon EMR [Información](#)

Una versión contiene un conjunto de aplicaciones que se puede instalar en el clúster.

Paquete de aplicaciones

Spark Interactive 	Core Hadoop 	Flink 	HBase 	Presto 	Trino 	Custom 
---	---	---	---	--	--	--

- | | | |
|---|---|--|
| ☐ AmazonCloudWatchAgent 1.300032.2 | ☐ Flink 1.20.0 | ☐ HBase 2.6.2 |
| ☐ HCatalog 3.1.3 | ☒ Hadoop 3.4.1 | ☒ Hive 3.1.3 |
| ☐ Hue 4.11.0 | ☐ JupyterEnterpriseGateway 2.6.0 | ☐ JupyterHub 1.5.0 |
| ☐ Livy 0.8.0 | ☐ Oozie 5.2.1 | ☐ Phoenix 5.2.1 |
| ☐ Pig 0.17.0 | ☐ Presto 0.287 | ☐ Spark 3.5.6 |
| ☐ TensorFlow 2.19.0 | ☐ Tez 0.10.2 | ☐ Trino 476 |
| ☐ Zeppelin 0.11.1 | ☐ ZooKeeper 3.9.3 | |

Configuración del Catálogo de datos de AWS Glue

Utilice el Catálogo de datos de AWS Glue para proporcionar un meta-almacén externo a la aplicación.

- ☐ Usar para metadatos de la tabla de Hive

▼ Configuración del clúster - *obligatorio* [Información](#)

Elija un método de configuración para los grupos principales, centrales y de nodos tareas para su clúster.

☒ Grupos de instancias uniformes

Elija el mismo tipo de instancia de EC2 y la misma opción de compra (bajo demanda o de spot) para todos los nodos de su grupo de nodos. [Más información](#)

☐ Flotas de instancias flexibles

Elija entre la más amplia variedad de opciones de aprovisionamiento para las instancias de EC2 de su clúster. Diversifique los tipos de instancias y las opciones de compra, y utilice una estrategia de asignación. [Más información](#)

Grupos de instancias uniformes

Principal

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria
Únicamente EBS almacenamiento
Precio bajo demanda: -
Precio de spot más bajo: -

Acciones ▼

☐ Utilice la alta disponibilidad

Lance un clúster más resiliente y de alta disponibilidad con tres nodos principales en instancias bajo demanda. Esta configuración se aplica durante toda la vida útil del clúster. [Más información](#)

► Configuración de nodo - *opcional*

Central

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria
Únicamente EBS almacenamiento
Precio bajo demanda: -
Precio de spot más bajo: -

Acciones ▼

Tarea 1 de 1

[Eliminar grupo de instancias](#)

Nombre

Tarea - 1

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria
Únicamente EBS almacenamiento
Precio bajo demanda: -
Precio de spot más bajo: -

Acciones ▼

▼ **Aprovisionamiento y escalado de clústeres - obligatorio** [Información](#)

Elija cómo Amazon EMR debe dimensionar su clúster.

Elija una opción

☒ **Establecer el tamaño del clúster manualmente**
Utilice esta opción si conoce los patrones de la carga de trabajo de antemano.

☐ **Utilizar escalado administrado por EMR**
Supervise las métricas clave de la carga de trabajo de modo que EMR pueda optimizar el tamaño del clúster y la utilización de los recursos.

☐ **Utilizar el escalamiento automático personalizado**
Para escalar mediante programación los nodos principales y los nodos de tarea, cree políticas de escalamiento automático personalizadas.

Configuración de aprovisionamiento

Establezca el tamaño del principal y tarea grupos de instancias. Amazon EMR intenta aprovisionar esta capacidad al lanzar el clúster.

Nombre	Tipo de instancia	Tamaño de instancia(s)	Utilizar la opción de compra de spot
Central	m4.large	2	☐
Tarea - 1	m4.large	1	☐

▼ **Configuración de seguridad y par de claves de EC2** [Información](#)

Elija una configuración de seguridad o cree una nueva que pueda reutilizar con otros clústeres.

Configuración de seguridad

Seleccione la configuración del servicio de cifrado, autenticación, autorización y metadatos de instancia del clúster.

 [Examinar](#) [Crear configuración de seguridad](#)

Par de claves de Amazon EC2 para el protocolo SSH al clúster [Información](#)

 [Examinar](#) [Crear par de claves](#)

Información

Elija o cree un rol de servicio y un perfil de instancia para las instancias de EC2 del clúster.

Información

El rol de servicio es un rol de IAM que Amazon EMR asume para aprovisionar recursos y realizar acciones de nivel de servicio con otros servicios de AWS.

- ☒ **Elegir un rol de servicio existente**
Seleccione un rol de servicio predeterminado o un rol personalizado con políticas de IAM asociadas para que el clúster pueda interactuar con otros servicios de AWS.

☐ **Crear un rol de servicio**
Deje que Amazon EMR cree un nuevo rol de servicio para que pueda conceder y restringir el acceso a los recursos de otros servicios de AWS.

Rol de servicio

EMR_DefaultRole



Perfil de instancia de EC2 para Amazon EMR

El perfil de instancia asigna un rol a cada instancia de EC2 de un clúster. El perfil de instancia debe especificar un rol que pueda acceder a los recursos de los pasos y las acciones de arranque.

- ☒ **Elegir un perfil de instancia existente**
Seleccione un rol predeterminado o un perfil de instancia personalizado con políticas de IAM asociadas para que el clúster pueda interactuar con sus recursos de Amazon S3.
 - ☐ **Crear un perfil de instancia**
Deje que Amazon EMR cree un nuevo perfil de instancia para que pueda especificar un conjunto personalizado de recursos a los que tendrá acceso en Amazon S3.

Perfil de instancia

EMR EC2 DefaultRole



```
C:\Users\Mañana>ssh -i "ClaveEMR.pem" hadoop@ec2-3-236-72-87.compute-1.amazonaws.com
```

```
#_
~\##### Amazon Linux 2023
~~~\#####\
~~~\###|
~~~\#/ --- https://aws.amazon.com/linux/amazon-linux-2023
~~~~V~'!->
~~~~~
~~~~~
~~~~~
~~~~~
~~~~~
```

EEEEEEEEEEEEEEEEEEEE	MMMMMMMM	MMMMMMMM	RRRRRRRRRRRRRRRR
E:::E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::R:::R:::R:::R:::R
EE:::EE:::EE:::EE:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::RRRRRR:::R
E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	RR:::R:::R:::R
E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::R:::R:::R
E:::E:::EEEEEEEEEE	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::RRRRRR:::R
E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::R:::R:::RR
E:::E:::EEEEEEEEEE	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::RRRRRR:::R
E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::R:::R:::R
E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::R:::R:::R
EE:::EE:::EE:::EE:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	R:::R:::R:::R
E:::E:::E:::E:::E	M:::M:::M:::M:::M	M:::M:::M:::M:::M	RR:::R:::R:::R
EEEEEEEEEEEEEEEEEEEE	MMMMMMMM	MMMMMMMM	RRRRRRRR

```
[hadoop@ip-172-31-76-223 ~]$
```

```
[hadoop@ip-172-31-76-223 ~]$ hive
Hive Session ID = 612e8343-c2f1-41e4-9ae7-017c29307579
```

```
Logging initialized using configuration in file:/etc/hive/conf.dist/hive-log4j2.properties Async: true
hive>
```

EJERCICIO 3

Tarea 3: Analizar los datos

En esta tarea, analizarás los datos de Ngrams en una sesión interactiva de Hive.

3.1 Examinar los datos sin procesar

En esta sección, accederás a los datos sin procesar de Ngrams. Accederás a los datos sobre *1-grams*, que proporcionan un recuento de las *palabras sueltas* que se encuentran en todos los libros. Estos datos tienen 261 millones de entradas y ocupan 2,6 GB de almacenamiento en disco.

Los datos de Ngram son accesibles desde Amazon S3 y se puede acceder a ellos directamente desde Amazon EMR mediante la creación de una *tabla externa*. Esta definición indica a Amazon EMR qué formato tienen los datos y dónde se encuentran.

12.  **Comando:** escribe el siguiente comando para crear la estructura de datos e identificar la ubicación de los datos de entrada:

```
CREATE EXTERNAL TABLE ngrams
(gram string, year int, occurrences bigint, pages bigint, books bigint)
ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t'
STORED AS SEQUENCEFILE
LOCATION 's3://datasets.elasticmapreduce/ngrams/books/20090715/eng-1M/1gram/';
```

```
hive> CREATE EXTERNAL TABLE ngrams
> (gram string, year int, occurrences bigint, pages bigint, books bigint)
> ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t'
> STORED AS SEQUENCEFILE
> LOCATION 's3://datasets.elasticmapreduce/ngrams/books/20090715/eng-1M/1gram/';
OK
Time taken: 6.245 seconds
```

Se ha creado la tabla **ngrams**. Un buen primer paso es ver la estructura de la tabla.

13.  **Comando:** escribe el siguiente comando para describir la estructura de la tabla:

```
DESCRIBE ngrams;
```

```
hive> describe ngrams
> ;
OK
gram                string
year                int
occurrences          bigint
pages                bigint
books                bigint
Time taken: 0.265 seconds, Fetched: 5 row(s)
```

14.  **Comando:** escribe el siguiente comando para mostrar los 10 primeros registros de la tabla:

```
SELECT * FROM ngrams LIMIT 10;
```

```
hive> SELECT * FROM ngrams LIMIT 10
> ;
OK
#      1574      1      1      1
#      1584      6      6      1
#      1614      1      1      1
#      1631     115     100     1
#      1632      3      3      1
#      1635      1      1      1
#      1640      1      1      1
#      1641      1      1      1
#      1642      5      5      1
#      1644     234     193     1
Time taken: 2.121 seconds, Fetched: 10 row(s)
```

3.2 Normalizar los datos

En los pasos siguientes, se limpian los datos. Este proceso conlleva:

- excluir las palabras de menos de tres caracteres
- excluir las palabras que contienen caracteres no alfabéticos (sí se aceptan guiones y apóstrofes)
- convertir todos los caracteres a minúsculas

En primer lugar, crearás una nueva tabla para almacenar los resultados de los datos normalizados.

15.  **Comando:** copia y pega este enunciado para crear una tabla que almacene los resultados de la normalización. Esta tabla solo contendrá las columnas de interés:

```
CREATE TABLE normalized
(gram string, year int, occurrences bigint);
```

```
hive> CREATE TABLE normalized
> (gram string, year int, occurrences bigint);
OK
Time taken: 0.492 seconds
```

A continuación, SELECCIONARÁS los datos de la tabla *ngrams* y luego los INSERTARÁS en la nueva tabla *normalized*. La consulta:

- Solo usará los datos entre 1990 y 2005.
- Convertirá los n-grams en minúsculas.
- Solo incluirá palabras de tres o más caracteres.
- Solo incluirá palabras que contengan caracteres alfabéticos, apóstrofes y guiones.

16.  **Comando:** copia y pega este enunciado para seleccionar los datos de la tabla *ngrams* e insertarlos en la tabla *normalized*:

```
INSERT OVERWRITE TABLE normalized
SELECT lower(gram), year, occurrences
FROM ngrams
WHERE year BETWEEN 1990 AND 2005
AND gram REGEXP "^[A-Za-z+\'-]{3,}$";
```



```
hive> INSERT OVERWRITE TABLE normalized
> SELECT lower(gram), year, occurrences
> FROM ngrams
> WHERE year BETWEEN 1990 AND 2005
> AND gram REGEXP "^[A-Za-z+\\'-]{3,}$";
Query ID = hadoop_20260112082506_d2f140a2-f6ec-462a-a14c-774b25519901
Total jobs = 1
Launching Job 1 out of 1
Tez session was closed. Reopening...
Session re-established.
Session re-established.
Status: Running (Executing on YARN cluster with App id application_1768205578899_0002)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1	container	SUCCEEDED	21	21	0	0	0	0	
Reducer 2	container	SUCCEEDED	1	1	0	0	0	0	

```
VERTICES: 02/02 [=====>>] 100% ELAPSED TIME: 172.72 s

Loading data to table default.normalized
OK
Time taken: 185.616 seconds
```

3.3 Examinar los datos normalizados

Ahora, tu trabajo de *Hive* tendría que haber finalizado. Una versión *limpia* de los datos estará ahora disponible en la tabla *normalized*. Ahora, examinarás los datos.

17.  **Comando:** escribe el siguiente comando para ver las 20 primeras filas de datos:

```
SELECT * FROM normalized LIMIT 20;
```

```
hive> SELECT * FROM normalized LIMIT 20;
OK
ingermany      1991      1
ingermany      1993      1
ingermany      1994      3
ingermany      1996      1
ingermany      2001      1
ingermany      2004      1
ingermany      2005      1
ingreece       1990      1
ingreece       2001      1
ingreece       2004      1
injuly 1990     7
injuly 1991     3
injuly 1992     6
injuly 1993     4
injuly 1994     1
injuly 1995     5
injuly 1996     4
injuly 1998     4
injuly 1999     3
injuly 2000     6
Time taken: 0.168 seconds, Fetched: 20 row(s)
hive> |
```

Un científico de datos estaría interesado en ver las palabras más populares en todos los libros.

18.  **Comando:** escribe el siguiente comando para ver las 50 palabras más usadas en todos los libros de todos los años:

```
-- Display the 50 most-used words
SELECT
  gram,
  sum(occurrences) as total_occurrences
FROM normalized
GROUP BY gram
ORDER BY total_occurrences DESC
LIMIT 50;
```

```
hive> SELECT
>   gram,
>   sum(occurrences) as total_occurrences
> FROM normalized
> GROUP BY gram
> ORDER BY total_occurrences DESC
> LIMIT 50;
Query ID = hadoop_20260112083040_7d429108-b51f-4cda-b523-210ebe2c8c7f
Total jobs = 1
Launching Job 1 out of 1
Status: Running (Executing on YARN cluster with App id application_1768205578899_0002)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1		container	SUCCEEDED	21	21	0	0	0	0
Reducer 2		container	SUCCEEDED	1	1	0	0	0	0
Reducer 3		container	SUCCEEDED	1	1	0	0	0	0

```
VERTICES: 03/03 [=====]>>> 100% ELAPSED TIME: 40.71 s
OK
```

the	600731810
and	269591500
that	94084329
for	80649257
with	61620362
was	57843905
this	45202579
are	44749547
from	40039900
not	38905683
his	33689806
have	31100386
but	29014171
which	28732316
you	27930990
they	27538747
had	26712182
were	24825903
their	24729315
one	23646682
all	21382534
can	19855720
her	19278458
has	18670586
more	18489067

```
there 17394454
when 17001334
been 16865057
she 16766345
other 16254322
who 16106638
would 16010618
these 15806270
will 15500621
its 15140867
also 14916919
what 14622550
new 14385290
may 14343882
about 13985002
time 13584842
some 13494834
than 13474829
into 13167016
only 13040294
such 12532977
out 12107615
them 11976858
two 11875246
see 11665869
Time taken: 41.425 seconds, Fetched: 50 row(s)
hive> |
```

Se espera que estas palabras cortas aparezcan con frecuencia, pero es probable que las palabras más largas sean más interesantes.

19.  **Comando:** escribe el siguiente comando para ver las 50 palabras más usadas de más de 10 caracteres:

```
-- Display the 50 most-used words longer than 10 characters
SELECT
  gram,
  sum(occurrences) as total_occurrences
FROM normalized
WHERE length(gram) > 10
GROUP BY gram
ORDER BY total_occurrences DESC
LIMIT 50;
```

```
hive> SELECT
>   gram,
>   sum(occurrences) as total_occurrences
> FROM normalized
> WHERE length(gram) > 10
> GROUP BY gram
> ORDER BY total_occurrences DESC
> LIMIT 50;
Query ID = hadoop_20260112083437_aefaf322-4da6-4a9f-9823-5bdb215d9e84
Total jobs = 1
Launching Job 1 out of 1
Status: Running (Executing on YARN cluster with App id application_1768205578899_0002)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1	container	SUCCEEDED	21	21	0	0	0	0	
Reducer 2	container	SUCCEEDED	4	4	0	0	0	0	
Reducer 3	container	SUCCEEDED	1	1	0	0	0	0	

VERTICES: 03/03 [=====>>] 100% ELAPSED TIME: 34.69 s

OK

development	4584319
information	4419750
international	2731441
relationship	2013252
significant	1762598
particularly	1709008
performance	1669887
understanding	1631334
environment	1511561
organization	1491293
established	1441713
association	1385892
individuals	1376707
differences	1353913
traditional	1314358
appropriate	1309280
application	1289144
distribution	1278733
environmental	1170366
temperature	1140588
independent	1120174
communication	1114437
introduction	1111958
administration	1107008
relationships	1022809
institutions	1015093
construction	1005391
professional	975041

```

characteristics 954706
immediately    946994
organizations   920193
description     910751
perspective     900008
alternative     893176
interpretation  879798
educational     836159
responsibility  834175
opportunity     832457
requirements    816417
circumstances  815399
possibility     814106
responsible     812455
contemporary    796036
experiences     773274
concentration   770073
interaction     757969
represented     755851
applications    754726
communities     753603
psychological   739307
Time taken: 35.129 seconds, Fetched: 50 row(s)
hive> |

```

3.4 Calcular la proporción del uso de palabras

Un científico de datos podría ahora estar interesado en cómo varía el uso de las palabras entre los diferentes años. La forma más sencilla de examinarlo es crear una nueva tabla que contenga una **proporción** entre la aparición relativa de cada palabra y el número total de palabras almacenadas durante el año.

Por ejemplo, si la palabra *nube* aparece 10 000 veces en un año y 13 000 veces al año siguiente, no está claro si esto es porque la palabra se hizo más popular o a que se incluyeron más libros en la base de datos. Al calcular una *proporción*, es posible comparar la *frecuencia relativa* de una palabra en comparación con todas las demás palabras en un año determinado.

20.  **Comando:** escribe el siguiente enunciado de *Hive* para crear la tabla *ratios*:

```

CREATE TABLE ratios
(gram string, year int, occurrences bigint, ratio double);

```

```

hive> CREATE TABLE ratios
> (gram string, year int, occurrences bigint, ratio double);
OK
Time taken: 0.051 seconds
hive> |

```

21.  **Comando:** copia y pega este enunciado para rellenar la tabla ratios con los datos calculados a partir de la tabla *normalized*:

```
INSERT OVERWRITE TABLE ratios
SELECT
  a.gram,
  a.year,
  sum(a.occurrences) AS occurrences,
  sum(a.occurrences) / b.total AS ratio
FROM normalized a
JOIN (SELECT year, sum(occurrences) AS total
      FROM normalized
      GROUP BY year) b ON (a.year = b.year)
GROUP BY a.gram, a.year, b.total;
```

```
hive> INSERT OVERWRITE TABLE ratios
> SELECT
>   a.gram,
>   a.year,
>   sum(a.occurrences) AS occurrences,
>   sum(a.occurrences) / b.total AS ratio
> FROM normalized a
> JOIN (SELECT year, sum(occurrences) AS total
>       FROM normalized
>       GROUP BY year) b ON (a.year = b.year)
> GROUP BY a.gram, a.year, b.total;
Query ID = hadoop_20260112084136_9f137df8-aaa9-4678-bd62-ee3c82262454
Total jobs = 1
Launching Job 1 out of 1
Tez session was closed. Reopening...
Session re-established.
Session re-established.
Status: Running (Executing on YARN cluster with App id application_1768205578899_0003)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 4		container	SUCCEEDED	21	21	0	0	0	0
Reducer 5		container	SUCCEEDED	2	2	0	0	0	0
Map 1		container	SUCCEEDED	21	21	0	0	0	0
Reducer 2		container	SUCCEEDED	4	4	0	0	0	0
Reducer 3		container	SUCCEEDED	1	1	0	0	0	0

```
Loading data to table default.ratios
OK
Time taken: 145.925 seconds
hive> |
```

Ahora puedes consultar, para cada año y palabra, el cambio en la proporción con respecto al año anterior. Para hacerlo, debes combinar la tabla de proporciones con ella misma para comparar los valores entre años.

22.  **Comando:** copia y pega este enunciado para calcular la diferencia de proporciones año tras año. El enunciado filtra todas las palabras con menos de 1000 apariciones para evitar que se produzcan incrementos extremos de palabras muy raras.

```
-- Words that most increased in popularity each year
SELECT year, gram, occurrences, CONCAT(CAST(increase AS INT), 'x increase') as increase FROM
(
  SELECT
    y2.gram,
    y2.year,
    y2.occurrences,
    y2.ratio / y1.ratio as increase,
    rank() OVER (PARTITION BY y2.year ORDER BY y2.ratio / y1.ratio DESC) AS rank
  FROM ratios y2
  JOIN ratios y1 ON y1.gram = y2.gram and y2.year = y1.year + 1
  WHERE
    y2.year BETWEEN 1991 and 2005
    AND y1.occurrences > 1000
    AND y2.occurrences > 1000
) grams
WHERE rank = 1
ORDER BY year;
```

```
hive> SELECT year, gram, occurrences, CONCAT(CAST(increase AS INT), 'x increase') as increase FROM
> (
>   SELECT
>     y2.gram,
>     y2.year,
>     y2.occurrences,
>     y2.ratio / y1.ratio as increase,
>     rank() OVER (PARTITION BY y2.year ORDER BY y2.ratio / y1.ratio DESC) AS rank
>   FROM ratios y2
>   JOIN ratios y1 ON y1.gram = y2.gram and y2.year = y1.year + 1
>   WHERE
>     y2.year BETWEEN 1991 and 2005
>     AND y1.occurrences > 1000
>     AND y2.occurrences > 1000
> ) grams
> WHERE rank = 1
> ORDER BY year;
Query ID = hadoop_20260112084614_78d02113-d6d2-4367-8325-41a049fc4f7d
Total jobs = 1
Launching Job 1 out of 1
Status: Running (Executing on YARN cluster with App id application_1768205578899_0003)
```



```
Status: Running (Executing on YARN cluster with App id application_1768205578899_0003)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 4		container	SUCCEEDED	18	18	0	0	0	0
Map 1		container	SUCCEEDED	18	18	0	0	0	0
Reducer 2		container	SUCCEEDED	1	1	0	0	0	0
Reducer 3		container	SUCCEEDED	1	1	0	0	0	0

```
VERTICES: 04/04 [=====]>>>] 100% ELAPSED TIME: 51.99 s
```

```
OK
1991 amyloid 6405 5x increase
1992 comm 18841 8x increase
1993 abstr 7033 6x increase
1994 carole 8358 7x increase
1995 mansfield 4570 3x increase
1996 polymerization 14442 8x increase
1997 tho 19259 8x increase
1998 oswald 8774 6x increase
1999 sql 12516 6x increase
2000 dlb 12369 10x increase
2001 dcs 6031 5x increase
2002 proust 6231 5x increase
2003 olfactory 8538 6x increase
2004 eeg 8873 5x increase
2005 rectum 6981 6x increase
Time taken: 53.196 seconds, Fetched: 15 row(s)
```

23. **Comando:** escribe el siguiente comando para ver cómo ha aumentado el uso de la palabra *internet*:

```
-- Occurrences of 'internet' in books by year?
SELECT
  year,
  occurrences
FROM ratios
WHERE gram = 'internet'
ORDER BY year;
```

```
hive> SELECT
>   year,
>   occurrences
> FROM ratios
> WHERE gram = 'internet'
> ORDER BY year;
Query ID = hadoop_20260112084924_c2ed4ae4-2525-417e-90f4-c7a5574121b9
Total jobs = 1
Launching Job 1 out of 1
Status: Running (Executing on YARN cluster with App id application_1768205578899_0003)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1		container	SUCCEEDED	18	18	0	0	0	0
Reducer 2		container	SUCCEEDED	1	1	0	0	0	0

```
VERTICES: 02/02 [=====]>>>] 100% ELAPSED TIME: 26.17 s
```

```
OK
1990      1201
1991      828
1992      1981
1993      5265
1994      8132
1995     14491
1996     21064
1997     26982
1998     30317
1999     40579
2000     50505
2001     55799
2002     55137
2003     55793
2004     40861
2005     39483
Time taken: 26.616 seconds, Fetched: 16 row(s)
hive> |
```

Por último, para divertirnos un poco, la siguiente consulta encuentra las palabras más populares de cada longitud durante el año 2000.

24.  **Comando:** escribe el comando siguiente:

```
-- Most popular words of each length
SELECT DISTINCT length, gram
FROM
(
  SELECT length(gram) AS length,
         gram,
         rank() OVER (partition by length(gram) order by occurrences desc) AS rank
  FROM ratios
) x
WHERE rank = 1
ORDER BY length;
```

```
hive> SELECT DISTINCT length, gram
> FROM
> (
>   SELECT length(gram) AS length,
>   gram,
>   rank() OVER (partition by length(gram) order by occurrences desc) AS rank
> FROM ratios
> ) x
> WHERE rank = 1
> ORDER BY length;
Query ID = hadoop_20260112085334_45a8758b-7ccd-4940-b1e8-60e701716172
Total jobs = 1
Launching Job 1 out of 1
Status: Running (Executing on YARN cluster with App id application_1768205578899_0003)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1		container	SUCCEEDED	18	18	0	0	0	0
Reducer 2		container	SUCCEEDED	2	2	0	0	0	0
Reducer 3		container	SUCCEEDED	6	6	0	0	0	0
Reducer 4		container	SUCCEEDED	1	1	0	0	0	0

VERTICES: 04/04 [=====>>>] 100% ELAPSED TIME: 43.47 s

OK

```
OK
3      the
4      that
5      which
6      people
7      between
8      american
9      different
10     university
11     development
12     relationship
13     international
14     administration
15     characteristics
16     responsibilities
17     industrialization
18     telecommunications
19     hyperparathyroidism
20     institutionalization
21     psychopharmacological
22     electroencephalography
23     electroencephalographic
24     cholangiopancreatography
25     methylenetetrahydrofolate
26     abcdefghijklmnopqrstuvwxyz
27     ooooooooooooooooooooooooooooo
28     trimethoprim sulfamethoxazole
29     methylenedioxymethamphetamine
```

```

26      abcdefghijklmnopqrstuvwxyz
27      ooooooooooooooooooooooooooooo
28      trimethoprim sulfamethoxazole
29      methylenedioxymethamphetamine
30      dipalmitoylphosphatidylcholine
31      dichlorodiphenyltrichloroethane
32      ooooooooooooooooooooooooooooo
33      ooooooooooooooooooooooooooooo
34      ooooooooooooooooooooooooooooo
35      ooooooooooooooooooooooooooooo
36      ooooooooooooooooooooooooooooo
Time taken: 43.974 seconds, Fetched: 34 row(s)
hive> |

```

Confirm complete lab

Completing the lab will also end the lab session. Make sure all tasks have been completed and you are done using the lab environment.

Cancelar

Complete Lab

Exploring Google Ngrams with Amazon EMR and Hive (Español de España)

Laboratorio de AWS Builder | ★ 4.5 (2) | 1h 15m | Español (España) +10 más

Estás viendo esta formación como parte de un plan de formación: [Data Analytics Learning Plan \(includes Labs\)](#) (Español de España)



¡Enhorabuena!

Esta formación la finalizaste el January 12, 2026

Volver al plan de formación

Volver al inicio

Además de las practicas que se proponen en el laboratorio responde a las siguientes preguntas:

1.-¿Qué contiene el bucket
s3://datasets.elasticmapreduce/ngrams/books/20090715/eng-1M/1gram/? ¿Cuánto
ocupa el archivo que contiene?

Contiene un archivo con las palabras sueltas que se encuentran en todos los libros en inglés, ocupa 2,6 GB.

2.- ¿Cuántos registros contiene la tabla ngrams que creaste en HIVE? ¿Desde qué año hasta qué año abarca la información que contiene?

```
hive> SELECT COUNT(*) FROM ngrams;
Query ID = hadoop_20260112090710_c97593d2-80e7-4dfd-847d-4304bc866d16
Total jobs = 1
Launching Job 1 out of 1
Tez session was closed. Reopening...
Session re-established.
Session re-established.
Status: Running (Executing on YARN cluster with App id application_1768205578899_0004)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1		container	SUCCEEDED	21	21	0	0	0	0
Reducer 2		container	SUCCEEDED	1	1	0	0	0	0

```
VERTICES: 02/02 [=====>>] 100% ELAPSED TIME: 184.72 s
OK
261823186
Time taken: 193.068 seconds, Fetched: 1 row(s)
```

Tiene exactamente 261.823.186 entradas

```
hive> SELECT year FROM ngrams GROUP BY year order by year ASC;
Query ID = hadoop_20260112092311_82efe843-0cd5-42cd-b50f-eb17905be871
Total jobs = 1
Launching Job 1 out of 1
Status: Running (Executing on YARN cluster with App id application_1768205578899_0004)
```

	VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1		container	SUCCEEDED	21	21	0	0	0	0
Reducer 2		container	SUCCEEDED	4	4	0	0	0	0
Reducer 3		container	SUCCEEDED	1	1	0	0	0	0

```
VERTICES: 03/03 [=====>>] 100% ELAPSED TIME: 189.53 s
OK
1520
1527
1541
1574
1575
1576
```

```

1981
1982
1983
1984
1985
1986
1987
1988
1989
1990
1991
1992
1993
1994
1995
1996
1997
1998
1999
2000
2001
2002
2003
2004
2005
2006
2007
2008
Time taken: 189.995 seconds, Fetched: 393 row(s)
hive> |

```

Contiene información desde el 1520 hasta el 2008

3.- En la creación de la tabla normalized ¿qué significa la expresión REGEXP "[A-Za-z+\\'-]{3,}\$"? ¿ Cuántos registros contiene la tabla normalized?

Significa palabras que contengan minúsculas, mayúsculas, apóstrofes y guiones y que tengan tres o más caracteres.

```

hive> SELECT COUNT(*) FROM normalized;
OK
20803439
Time taken: 0.108 seconds, Fetched: 1 row(s)

```

Tiene 20.803.439 registros.