



AWS GLUE DATABREW

APARTADO A

1.- Realiza el ejemplo de Proyecto Databrew (trabajo y recetas) que se muestra en el tema UT_08.4_AWS DataBrew entre las páginas 1 y 7.

El primer paso es entrar a Glue DataBrew y Crear el proyecto de muestra con los datos de ChEMBL, utilizando el LabRole de AWS Academy:



☐ **Votaciones de la Asamblea General de las Naciones Unidas: Votos**
votes.csv | Valores separados por comas (CSV) file | 34,9 MiB

Todas las resoluciones documentadas de los votos de la Asamblea General de las Naciones Unidas desde su creación en 1946. El archivo de resolución contiene campos para un resumen anual de los registros de voto miembro-estado con puntuaciones de afinidad y una estimación de punto ideal en relación con los Estados Unidos. Este archivo es el tercero de los tres archivos (resolution.csv, states.csv y votes.csv).

☐ **Colección del Metropolitan Museum of Art**
dataset-met-objects.json | JSON file | 6,6 MiB

El conjunto de datos del Museo Metropolitano de Arte contiene información sobre más de 470 000 obras de arte de su colección para uso comercial y no comercial sin restricciones.

☐ **Nombres populares del año 2020**
dataset-national-baby-names.json | JSON file | 3,7 MiB

Nombres de bebé populares en 2020 en los Estados Unidos con registros de seguimiento de nombre, sexo y número de incidencias del nombre.

☒ **Datos de descubrimiento de fármacos de ChEMBL**
chembl-27.parquet | Parquet file | 2,2 MiB

ChEMBL es una base de datos administrada de manera manual de moléculas bioactivas con propiedades similares a los fármacos. Aúna datos químicos, de bioactividad y genómicos para ayudar a traducir la información genómica en nuevos fármacos eficaces.

☐ **Movimientos de partidas de ajedrez famosos**
chess-games.xlsx | Microsoft Excel file | 4,4 MiB

Toda la información disponible sobre 20 000 partidas de ajedrez y la cantidad de factores meta (ajenos al juego) que afectan a una partida.

Nombre del rol
Elija el rol que tiene acceso para conectarse a los datos. Actualice para ver las últimas actualizaciones.

LabRole ▼

↻

Cancelar

Crear proyecto

Nada más crear el proyecto, se creará una sesión que tarda alrededor de un minuto en instanciarse.

Tras crearse la sesión, veremos un interfaz de trabajo con los datos mostrados de forma tabular, con un menú superior con las operaciones/transformaciones disponibles, y donde podemos observar cómo tenemos 39 columnas y que sólo se están mostrando 500 filas. Para cada columna, podemos ver un gráfico con diversa información estadística y luego datos de ejemplo de dicha columna. Finalmente, en la parte derecha tenemos los pasos (la receta) que se aplican al dataset:



Receta (0)



Sample recipe - 1

Versión de trabajo



Más



Cree su receta


Comience a aplicar pasos de transformación a los datos. Se hará un seguimiento de todos los pasos de preparación de los datos en la receta.



Agregar paso

Una vez tenemos el entorno listo, vamos a realizar un conjunto de transformaciones que añadiremos a nuestra receta:

- El primer paso será eliminar la última columna, tid_fixed que tiene todos los valores nulos. Para ello, bien desde el menú Columna, seleccionamos la opción de Eliminar.



Columnas de origen

Nombre de la columna que se va a eliminar

☐ # mc_tax_id

☐ ABC mc_organism

☐ ABC mc_target_type

☐ ABC mc_target_name

☐ ABC mc_target_accession

☐ # cell_id

☐ ABC bao_format

☐ # tissue_id

☐ ABC curation_comment

☐ # variant_id

☐ ABC aidx

☐ # job_id

☐ # log_id

☐ ABC ridx

☒ # tid_fixed

Aplicar

<

Eliminar columna

×

Columnas de origen

Nombre de la columna que se va a eliminar

Nombre de la columna

▼

tid_fixed

×

👁 Vista previa de los cambios

Cancelar

Aplicar

- A continuación, vamos a filtrar datos. Por ejemplo, seleccionamos la columna `curated_by` y seleccionamos para que sea exactamente `Autocuration`. En la parte derecha podremos ver una pequeña estadística de los valores existentes y si pulsamos sobre Vista previa, se marcarán en rojo las filas que se eliminarán.

[illegible]

Nombre de la columna que se va a filtrar

Nombre de la columna ▲

Q |

- ABC assay_strain
- ABC assay_tissue
- ABC assay_cell_type
- ABC assay_subcellular_fraction
- # tid
- ABC relationship_type
- # confidence_score
- ABC curated_by
- # activity_count
- ABC assay_source
- # src_id
- ABC src_assay_id
- ABC chembl_id
- ABC updated_by
- ABC orig_description

CUADRÍCULA ESQUEMA PERFIL

ORIGEN	# activity_count
ABC curated_by	
Distintiva 1 Única 0 Total 390	Distintiva 40 Única 12 Total 384
Autocuration 390 100%	Mín. 1 Mediana 2 Media 8,65 Modo 1 Máx. 399
Autocuration 1	
Autocuration 1	
Autocuration 3	
Expert 23	
Autocuration 48	
Autocuration 1	
Autocuration 22	
Autocuration 1	
Expert 1	
Autocuration 48	
Autocuration 3	
Autocuration 9	
Autocuration 36	
Autocuration 1	
Autocuration 2	
Autocuration 1	
Autocuration 1	

Valores de filtro

Columna de origen
Nombre de la columna que se va a filtrar

curated_by ▼

Condición de filtro

Es exactamente ▼

☒ Ingresar valor personalizado ☐ Ingresar un valor de RegEx

Autocuration

Find

☐ Valores distintivos (0)

☐ Autocuration 390 78%

☐ Intermediate 96 19%

☐ Expert 14 2%

Vista previa mostrada

< **Valores de filtro** ×

curated_by ▼

Condición de filtro

Es exactamente ▼

☒ Ingresar valor personalizado ☐ Ingresar un valor de RegEx

Autocuration

Find

☐ **Valores distintivos (0)**

☐ Autocuration		390	78%
☐ Intermediate		96	19%
☐ Expert		14	2%

Vista previa mostrada

Cancelar

Aplicar

- Ahora nos vamos a centrar en la gestión de los valores nulos. Para ello, en la columna assay_organism cambiaremos los nulos por Unknown, utilizando el menú Faltante y la opción de Rellenar con valor personalizado:

n (390 filas)

Antifungal activity against Ca

Eliminar filas faltantes

Rellenar con valor personalizado

Rellenar con un valor vacío

Rellenar con nulo

Rellenar con el valor más frecuente

Rellenar con el último valor válido

Rellenar con agregación numérica

Única :
st Candida glab
alnst Listeria m
alnst vancomyc

Media
68,35

Columna de origen

Nombre de la columna con valores faltantes

Nombre de la columna ▲

Q

assay_id

doc_id

ABC description

ABC assay_type

ABC assay_test_type

ABC assay_category

ABC assay_organism

assay_tax_id

ABC assay_strain

ABC assay_tissue

ABC assay_cell_type

ABC assay_subcellular_fraction

tid

ABC relationship_type

confidence_score

ABC created_by

os valore

○ Filas filtradas: 0 filtros aplicados(390/390 fil



Valores faltantes



Columna de origen

Nombre de la columna con valores faltantes

assay_organism ▼

Acción de valor faltante

Acción que se debe realizar en los valores que faltan

- ☐ Eliminar filas con valores faltantes
- ☐ Rellenar con un valor vacío
- ☐ Rellenar con nulo
- ☐ Rellenar con el último valor válido
- ☐ Rellenar con el valor más frecuente
- ☒ Rellenar con valor personalizado
- ☐ Rellenar con agregación numérica

Valor personalizado

Unknown

Aplicar transformación a

- ☒ Todas las filas (390 filas)
La transformación se aplicará a todas las filas del conjunto de datos
- ☐ Filas filtradas: 0 filtros aplicados(390/390 filas)
La transformación se aplicará a las filas filtradas en la cuadrícula

<

Valores faltantes

×

assay_organism ▾

Acción de valor faltante

Acción que se debe realizar en los valores que faltan

☐ Eliminar filas con valores faltantes

☐ Rellenar con un valor vacío

☐ Rellenar con nulo

☐ Rellenar con el último valor válido

☐ Rellenar con el valor más frecuente

☒ Rellenar con valor personalizado

☐ Rellenar con agregación numérica

Valor personalizado

Unknown

Aplicar transformación a

☒ Todas las filas (390 filas)

La transformación se aplicará a todas las filas del conjunto de datos

☐ Filas filtradas: 0 filtros aplicados(390/390 filas)

La transformación se aplicará a las filas filtradas en la cuadrícula

👁 Vista previa mostrada

Cancelar

Aplicar

Si trabajamos con fechas es muy común crear columnas nuevas con información más útil. En nuestro caso, vamos a añadir una columna que llamaremos Mes con el nombre del mes que conseguimos con la función MONTHNAME sobre la columna updated_on. Para ello, desde el menú Funciones seleccionamos la función de fecha que nos interesa y configuramos los valores:

Crear columna

Opciones de creación de columnas

Basado en funciones ▼

Seleccionar una función

Crear una columna basada en la función seleccionada

MONTHNAME ▼

MONTHNAME

Devuelve en una nueva columna el nombre que corresponde al número del mes, en función de la columna de origen o un valor de entrada.


Valores que utilizan

Columna de origen ▲

Columna de origen

Valor personalizado

Nombre de la columna ▼



Columna de destino

CUADRÍCULA

ESQUEMA

PERFIL

ORIGEN				VISTA PREVIA			
updated_on				Mes			
Distintiva	265	Única	237	Distintiva	13	Única	0
Total	337	Total	337	Total	337	Total	337
5%	53	13,59%	53	16,41%	64	16,41%	64
2013-02-14 14:00:47	31	7,95%	31	13,85%	54	13,85%	54
2012-05-30 11:16:11	6	1,54%	6	13,59%	53	13,59%	53
Todos los demás valores	300	76,92%	300	56,15%	219	56,15%	219
2013-04-08 15:03:54				April			
2016-12-19 13:30:13				December			
2011-04-08 10:46:23				April			
2014-01-07 13:09:06				January			
2014-02-14 00:00:00				February			
2016-05-09 15:29:11				May			
2015-09-10 13:00:16				September			
2012-02-01 12:46:11				February			
2014-01-07 15:51:20				January			
null				null			
2014-01-07 16:10:50				January			
2012-11-02 16:02:54				November			
2015-12-04 14:44:48				December			
2015-12-04 14:45:50				December			
2013-07-17 09:22:45				July			
2013-03-31 00:44:39				March			
null				null			

Crear columna

columna de origen o un valor de entrada.

Valores que utilizan

Columna de origen

Columna de origen

updated_on

Columna de destino

Nombre de la columna creada con valores extraídos

Mes

Los caracteres válidos son alfanuméricos, guiones bajos y espacios

Aplicar transformación a

Todas las filas (390 filas)

La transformación se aplicará a todas las filas del conjunto de datos

Filas filtradas: 0 filtros aplicados(390/390 filas)

La transformación se aplicará a las filas filtradas en la cuadrícula

Vista previa mostrada

Cancelar

Aplicar

.- Una vez ya tenemos nuestra receta completa con todos los pasos necesarios en nuestra transformación, llega el momento de publicarla para crear una versión de esta y posteriormente poder reutilizarla.



Receta (4)



Sample recipe - 1

Versión de trabajo



Publicar



Más

Pasos aplicados (4) | [Borrar todo](#)



1. Eliminar columna `tid_fixed`

2. Valores de filtro por `curated_by`

3. Rellenar valores faltantes con Unknown en `assay_or_ganism`

4. Crear columna Mes uso de Func [Editar](#) [Eliminar](#)
`_NAME`

Publicar receta

La publicación de una receta creará una nueva versión de la receta. Las versiones publicadas de las recetas se pueden seleccionar como opciones para un trabajo de receta.

Nombre de la receta

Sample recipe - 1

Descripción de la versión

Pasos de la receta (4)

1. Eliminar columna `tid_fixed`

2. Valores de filtro por `curated_by`


3. Rellenar valores faltantes con Unknown en `assay_organism`

4. Crear columna Mes uso de Función `dateTime MONTH_NAME`

Cancelar

Publicar

6.- Si vamos al menú de las recetas, seleccionamos la receta recién publicada, en nuestro caso Sample recipe-2, y creamos un trabajo (job) con la misma, en el cual, tras darle un nombre y seleccionar el dataset, vamos a guardar el resultado en S3 tanto en formato CSV como en formato Parquet particionado por la columna Mes, y finalmente seleccionamos el rol LabRole:



Recetas (1)

Descargar como YAML

Descargar como JSON

Crear trabajo con esta receta

Acciones

Cargar receta

Buscar recetas

Publicado

☒	Nombre de la receta	Descripción de la versión	Proyectos asociados	Fecha de publicación	Publicado por	Etiquetas
☒	Sample recipe - 1 Versión publicada 1.0	-	Sample project - 1	hace un minuto 21 de enero de 2020, 12:17:19 pm	vociabs	-

DataBrew > Trabajos > Crear trabajo

Crear trabajo

Detalles del trabajo

Nombre del trabajo

Identificador del trabajo

Sample-job

El nombre del trabajo debe contener entre 1 y 240 caracteres. Los caracteres válidos son alfanuméricos (A-Z, a-z, 0-9), guiones (-), puntos (.) y espacios.

Tipo de trabajo

Tipo de trabajo que se va a ejecutar en el conjunto de datos

☒ **Crear un trabajo de receta**
Ejecuta las transformaciones de la receta asociada en la población del conjunto de datos asociado.

☐ **Crear un trabajo de perfil**
Genera un resumen y estadísticas que le dan la forma de los datos.

Entrada del trabajo

El conjunto de datos de entrada para el trabajo y la receta que se le aplicará.

Ejecutar en

☒ **Conjunto de datos**
Ejecute el trabajo en un conjunto de datos DataBrew existente o nuevo.

☐ **Proyecto**
Ejecute el trabajo en un proyecto sin trabajo asociado.

Elegir conjunto de datos

Introducir el nombre del conjunto de datos

Explorar conjuntos de datos

Conectar nuevo conjunto de datos

Receta asociada

Sample recipe - 1

Versión de la receta

Versión 1.0

Configuración de salida del trabajo

La ejecución de un trabajo genera archivos de salida en los destinos de archivo especificados.

Salida 1

[Configuración](#)[Remover](#)

Salida a

Ubicación de la salida

Amazon S3

Tipo de archivo

Formato de salida

CSV

Delimitador

Separador CSV

Coma (,)

Compresión

Tipos disponibles

None

Cuenta de AWS del propietario del bucket de S3

☒ Cuenta de AWS actual
499648412025

☐ Otra cuenta de AWS

Ubicación de S3

El formato es s3://bucket/folder/

s3://bucket-receta-sample/csv/

Explorar

Resumen de configuración

Almacenamiento de salida de archivos

Crear una nueva carpeta para cada ejecución de flujo de trabajo

Salida de archivo

Autogenerate files

División personalizada por valores de columna

Desactivado

Vista previa de la ruta de salida

s3://bucket-receta-sample/csv/Sample-job_21ene.2026_timestamp_part00000.csv

Salida 2

[Configuración](#)[Remover](#)

Salida a

Ubicación de la salida

Amazon S3

Tipo de archivo

Formato de salida

PARQUET

Delimitador

Separador CSV

Coma (,)

Compresión

Tipos disponibles

None

Cuenta de AWS del propietario del bucket de S3

☒ Cuenta de AWS actual
499648412025

☐ Otra cuenta de AWS

Ubicación de S3

El formato es s3://bucket/folder/

s3://bucket-receta-sample/parquet/

Explorar

Resumen de configuración

Almacenamiento de salida de archivos

Crear una nueva carpeta para cada ejecución de flujo de trabajo

Salida de archivo

Autogenerate files

División personalizada por valores de columna

Desactivado

Vista previa de la ruta de salida

s3://bucket-receta-sample/parquet/Sample-job_21ene.2026_timestamp_part00000.parquet

[Agregar otra salida](#)

► Configuración adicional - opcional



Configuración

Remover

Resumen de configuración

Almacenamiento de salida de archivos

Crear una nueva carpeta para cada ejecución de flujo de trabajo

Salida de archivo

Autogenerate files

Configuración de 2 de salida



Almacenamiento de salida de archivos

☒ Crear una nueva carpeta para cada ejecución de flujo de trabajo

En la ruta de S3 especificada, se creará una nueva carpeta para cada ejecución de trabajo y para cada tipo de archivo de salida. El nombre de archivo y la carpeta de salida contienen el nombre del trabajo y el tiempo en el que se ejecutó el trabajo. Ejemplo: s3://bucket/myfolder/jobname_10may2020_timestamp/filetype_compression/jobname_10may2020_timestamp_part1.csv

☐ Reemplazar archivos de salida para cada ejecución de flujo de trabajo

Los archivos de salida sin formato se crean en la ruta de S3 especificada. Para cada ejecución de trabajo, los archivos de salida anteriores se sustituyen por archivos de la última ejecución de trabajo. Para poder restaurar versiones de archivos anteriores, active el control de versiones del bucket. Ejemplo: s3://bucket/micarpeta/nombredetrabajo_parte1.csv

Partición de archivos

Configuraciones para los archivos de salida generados. [Más información](#)

Opciones de salida de archivos

☒ Generar archivos automáticamente (Recomendado)

Configuración de salida de archivos predeterminada que genera varios archivos. Por lo general, da como resultado el tiempo de ejecución más rápido del trabajo.

☐ Salida de un único archivo

Se genera un único archivo de salida. Los archivos más grandes pueden aumentar los tiempos de ejecución de los trabajos.

☐ Salida de varios archivos

Especifique el número máximo de archivos en los que desea dividir la salida.

División personalizada por valores de columna

Divida la salida en archivos más pequeños según los nombres de las columnas que especifique. Las rutas de carpeta de los archivos de salida resultantes constan de todas las combinaciones únicas posibles de valores para las columnas seleccionadas. Ejemplo: un archivo con particiones según las columnas A y B se almacena en esta ruta de S3: s3://output file path.../Column A/Column B/ [Más información](#)

☐ Desactivado

☒ Activado

Columnas según las que crear particiones

Q Mes



Agregar

Cancelar

Guardar

Entrada del trabajo

El conjunto de datos de entrada para el trabajo y la receta que se le aplicará.

Ejecutar en

☒ Conjunto de datos

Ejecute el trabajo en un conjunto de datos DataBrew existente o nuevo.

☐ Proyecto

Ejecute el trabajo en un proyecto sin trabajo asociado.

Elegir conjunto de datos

Q chembl-27



Explorar conjuntos de datos

Conectar nuevo conjunto de datos

Receta asociada

[Sample recipe - 1](#)

Versión de la receta

Versión 1.0



Permisos

DataBrew needs permission to connect to data on your behalf. Use an IAM role with the [política necesario](#) attached.

Nombre del rol

Elija el rol que tiene acceso para conectarse a los datos. Actualice para ver las últimas actualizaciones.

LabRole




Cancelar

Crear trabajo

Crear y ejecutar trabajo

2.- Muestra también el linaje resultante de los datos.

Para ver el linaje de datos debemos ir a la sección de trabajos, seleccionar el trabajo cuyo linaje queremos ver y después hacer click en “linaje de datos”



Trabajos de recetas (1)

Q

Buscar trabajos

☐

Nombre del trabajo ▾


Estado

☐

Sample-job

✓

 Realizado con



Historial de la ejecución del trabajo	Detalles del trabajo	<u>Linaje de datos</u>

